

欠測 IV と潜在変数モデリングによる 非無作為欠測の識別

多変量 MNAR のノンパラメトリック識別とオンラインレビューへの応用

本多 将大 星野 崇宏 大津 泰介

慶應義塾大学・理化学研究所・London School of Economics and Political Science

日本統計学会研究報告

Motivation : 多変量 MNAR からマーケティング実証へ

マイクロデータの非観測問題

欠測値, 選択, 反実仮想の非観測は頻繁に生じる。MNAR では未観測値自身が観測確率を動かすため,

$$\mathbb{P}(D = 1 \mid Y, X) \text{ depends on } Y \Rightarrow f(Y \mid D = 1, X) \neq f(Y \mid X).$$

観測集団だけに基づく推論は一般に偏る。

欠測 IV によるノンパラメトリック識別

選択だけを動かす通常の IV では, アウトカム分布全体の点識別は困難である。一方, d'Haultfoeuille (2010) は

$$D \perp\!\!\!\perp V \mid Y, X, \quad V \not\perp\!\!\!\perp Y \mid X$$

と完備性の下で, 欠測アウトカムの分布を関数形なしに識別した。近年は自己値依存・他項目依存の多変量 MNAR についても識別・推定が示されている (Y. Li et al. 2023; Malinsky et al. 2022)。

オンラインレビューは制約付き多変量 MNAR である

レビュー投稿は自己選択的で, 極端な経験を選ぶ polarity self-selection により, 公開評価は J 字型または polar な分布になる (N. Hu et al. 2017; Schoenmueller et al. 2020)。

個人 i は m 個の私的評価を持つが, 認知的・行動的な投稿コストにより公開できるのは $K_i < m$ 件である。


$$\mathbf{Y}_i = (Y_{i1}, \dots, Y_{im})', \quad \sum_{j=1}^m D_{ij} = K_i.$$

このとき多数の潜在的レビューが有限の開示枠を競い, D_{ij} は自己値 Y_{ij} と他項目 $\mathbf{Y}_{i,-j}$ の双方に依存する。

中心的な問い

構造的ゼロと cross-item crowd-out をもつ分布から, 平均評価や極端評価率をどこまでノンパラメトリックに回復できるか。

多変量 MNAR では、項目 j の公開が評価ベクトル全体に依存する



$$Y_{ij}^{\text{obs}} = D_{ij} Y_{ij}, \quad O_i = (X_i, K_i, V_i, D_i, Y_i^{\text{obs}}).$$

既存の二つの censoring 関係

Self-censoring:

$$D_{ij} \perp\!\!\!\perp Y_{i,-j} \mid X_i, Y_{ij}, D_{i,-j}.$$

No self-censoring:

$$D_{ij} \perp\!\!\!\perp Y_{ij} \mid X_i, Y_{i,-j}, D_{i,-j}.$$

容量制約付き選択

$$\mathbb{P}(D_{ij} = 1 \mid Y_i, X_i, K_i)$$

は Y_{ij} と $Y_{i,-j}$ の双方に依存する。したがって既存のどちらの censoring 独立性にも一般に属さない。

Shadow-variable route

$C_{ij} = (X_i, K_i, V_{i,-j})$ を常時観測文脈とし、

$$D_{ij} \perp\!\!\!\perp V_{ij} \mid Y_{ij}, C_{ij}, \quad V_{ij} \not\perp\!\!\!\perp Y_{ij} \mid C_{ij}$$

▷ target-specific bridge により、平均・観測率を直接回復する。

本研究は方法論を実験で検証し、プラットフォーム増幅へ拡張する

1. 方法論

容量制約付き **multiple selection** を、構造的ゼロと項目間依存をもつ多変量 **MNAR** として定式化する。既存モデルと識別仮定が異なるため、平均・裾確率の **target-specific bridge** によるノンパラメトリック識別を与える。

2. 実験 1

同一標本から全項目の私的評価 (**oracle**) と公開評価 (**public**) を取得する。開示容量 K_i をランダム化し、**MNAR** の **crowd-out** と識別・回復性能を直接比較する。

3. 実験 2

発展的に、実際の擬似プラットフォームで **random**, **helpfulness**, 生成 AI ランキングを比較し、投稿段階の歪みが表示アルゴリズムによって増幅されるかを検証する。

期待される成果とアウトリーチ


観察される公開評価から母集団の評価汎関数を回復する理論と実証を得る。統計学、情報理論、経済学、商学、心理学、機械学習を横断し、SNS、口コミ、体験談、苦情投稿などの投稿コストと取得データが社会的評価分布に与える影響を明らかにする。

既知なのは極端性，未解明なのは経験間の競争である

先行研究が示したこと

- ▶ 低頻度レビュアーほど 1・5 星が過剰になる。
- ▶ self-selected review は forced review より極端になる。
- ▶ acquisition bias と underreporting bias により公開分布は母集団を代表しない。

Panel A: Secondary Yelp Data
Polarity self-selection by # of restaurant reviews/reviewer
($n_{users} = 355,878$, $n_{reviews} = 3,649,186$)



私的評価 10 件 (例)

5 4 3 2 5 1 3 4 2 3

$K = 5$ 5 5 1 4 4

$K = 3$ 5 5 1

$K = 1$ 5

$K \downarrow$
裾へ集中

本研究が追加する比較

$K_i \downarrow \implies$ 高 salience 経験への集中 $\implies$ cross-item crowd-out.

Y_{ij} を固定しても，他項目により強い経験があると j は公開枠から押し出される。この依存構造と K_i の因果効果を明示的に検証する。

Source of left figure: Schoenmueller et al. (2020), Figure 3.

Strategic sample selection を欠測パターンへ写像する

既存の selected experiment

候補 k 個から上位 n 個を観測する (Di Tillio et al. 2021)。

$$X_1 \geq \dots \geq X_n = \text{top } n \text{ of } k > n.$$

最大値の分布は

$$G_1(x | \theta) = F^k(x | \theta)$$

となり、ランダム標本とは異なる。




FIGURE 1.—Maximal selection provides more accurate information with normal noise (left) but less accurate information with exponential noise (right).

本研究の統計的写像

$$D_i = r_{K_i} \{A_i(Y_i, X_i, \varepsilon_i)\}, \quad Y_{ij}^{obs} = D_{ij} Y_{ij}.$$

経済的な選択集合を、多変量欠測パターン D_i として扱う。

Source: Di Tillio et al. (2021), Figure 1.

レビューへの読み替え

$$\underbrace{k}_{\text{presample}} \leftrightarrow \underbrace{m}_{\text{経験数}}, \quad \underbrace{n}_{\text{sample}} \leftrightarrow \underbrace{K_i}_{\text{公開枠}}.$$

選択方程式は generalized Roy model に含まれる

包含関係

各レビュー候補には公開効用 A_{ij} があり、個人は容量 K_i の下で

$$S_i(K_i) \in \arg \max_{|S| \leq K_i} \sum_{j \in S} A_{ij}$$

を選ぶ。これは非金銭的効用と複数選択を許す **capacity-constrained generalized Roy model** と読める。

新規性を主張しない部分

d'Haultfoeuille (2010) は shadow IV を unobserved-sector Roy model へ適用できることを既に示している。したがって「Roy model への shadow-variable 法の適用」自体は本研究の新規性ではない。

本研究が検証する部分

1. exact top- K による構造的ゼロ；
2. 他項目との競争による cross-item crowd-out；
3. oracle と public を同一標本から得る回復性能；
4. K_i とランキングのランダム化による因果比較。

位置づけ

方法論の中心は新しい Roy 識別定理ではなく、容量制約付きレビューを dependent multivariate MNAR として実装し、選択機構と shadow 補正を直接評価することである。

既存の多変量 MNAR は top-K の支持集合と両立しない

モデル	識別仮定	top-K との相違
Self-censoring	$D_j \perp\!\!\!\perp Y_{-j} \mid X, Y_j, D_{-j}$ 。加えて各 supported pattern の positivity と、 $d \leq d'$ なら d' も supported という upward closure を置く。	$\sum_j D_j = K < m$ では上位パターン、特に $\mathbf{1}_m$ が存在せず、upward closure が破れる。
No self-censoring	$D_j \perp\!\!\!\perp Y_j \mid X, Y_{-j}, D_{-j}$ と $\mathbb{P}(\mathbf{D} = \mathbf{1}_m \mid \mathbf{Y}, X) > \sigma$ 。	自己値が公開を動かす極端性選択を排除し、完全ケース positivity も破れる。
Complete-case missing IV	$R^{cc} \perp\!\!\!\perp V \mid \mathbf{Y}, X, \mathbb{P}(R^{cc} = 1 \mid \mathbf{Y}, X) > 0$ 。	$R^{cc} = \mathbf{1}\{\mathbf{D} = \mathbf{1}_m\} = 0$ a.s. で、識別モーメント自体が消える。
本研究	項目・supported block ごとに shadow condition と target-specific representer bridge を置く。	平均・裾確率を直接回復する。分布全体の識別には追加の完備性を要する。

Sources: d'Haultfoeuille (2010), Y. Li et al. (2023), and Malinsky et al. (2022).

公開効用は positive WOM と negative WOM の二経路をもつ

個人 i の財 j に対する公開動機を

$$M_{ij}^+ = f_+((Y_{ij} - c_0)_+, \mathbf{Y}_{i,-j}, \mathbf{X}_i), \quad M_{ij}^- = f_-((c_0 - Y_{ij})_+, \mathbf{Y}_{i,-j}, \mathbf{X}_i)$$

とする。 M^+ は self-enhancement・他者支援・企業支援, M^- は negative feelings の解放・他者への警告を含む (Berger 2014; Hennig-Thurau et al. 2004)。

$$A_{ij} = a_+(M_{ij}^+) + a_-(M_{ij}^-) - \kappa_{ij} + \varepsilon_{ij}, \quad a'_+, a'_-, f'_+, f'_- \geq 0. \quad (\text{U})$$

評価から公開効用への単調経路

$Y_{ij} > c_0$ では positive WOM, $Y_{ij} < c_0$ では negative WOM が公開効用を高め得る。したがって極端性は公開効用を高めるが、正負の傾きは等しい必要がない。

容量制約が公開集合を決める

開示集合は

$$S_i(B_i) \in \arg \max_{S \subseteq \{1, \dots, m\}} \sum_{j \in S} A_{ij} \quad \text{s.t.} \quad \sum_{j \in S} c_{ij} \leq B_i, \quad D_{ij} = \mathbf{1}\{j \in S_i(B_i)\}. \quad (\text{SEL})$$

Top-K 特殊ケース

$c_{ij} = 1$, $B_i = K_i$, 同順位なし, かつ正確に K_i 件を選ぶなら

$$D_{ij} = \mathbf{1}\{A_{ij} \geq A_{i, (K_i)}\},$$

ただし $A_{i, (K_i)}$ は降順 K_i 番目の公開効用である。

命題 1 : Top-K は自己単調性と crowd-out を生む

命題 1 (自己単調性と競合経験効果)

同順位がない exact top-K 選択を考える。他の効用を固定すると

$$A_{ij} \uparrow \implies D_{ij} \text{ は弱く増加する.}$$

一方, A_{ij} と $\mathbf{A}_{i,-\{j,\ell\}}$ を固定すると

$$A_{i\ell} \uparrow \quad (\ell \neq j) \implies D_{ij} \text{ は弱く減少する.} \quad (\text{CO})$$

識別可能な比較静学

自己効用 A_{ij} を固定しても, 競合する $A_{i\ell}$ が上がれば j の公開確率は弱く下がる。これは itemwise 独立選択にはない **experience-level crowd-out** である。

命題 2：公開容量が小さいほど選択効用は高くなる

命題 2（容量比較静学）

$A_{i(1)} \geq \cdots \geq A_{i(m)}$ とし

$$\bar{A}_i(K) = K^{-1} \sum_{r=1}^K A_{i(r)}$$

と置く。 $K_1 < K_2$ なら

$$\bar{A}_i(K_1) \geq \bar{A}_i(K_2). \quad (\text{CAP})$$

salience s_{ij} について同じ結論を得るには

$$\text{ord}\{A_{ij}\}_{j=1}^m = \text{ord}\{s_{ij}\}_{j=1}^m \quad \text{a.s.}$$

が必要である。単に $A_{ij} = v(s_{ij}) + \varepsilon_{ij}$ と置くだけでは順位一致は従わない。

実験仮説：U字型の裾過剰とJ字型の非対称を区別する

評価の方向別 salience を

$$s(y) = \alpha_+(y - c_0)_+ + \alpha_-(c_0 - y)_+, \quad \alpha_+, \alpha_- \geq 0$$

とする。

U字型を導く追加条件

$$\alpha_+ = \alpha_- > 0$$

に加え、公開効用の順位が極端性順位と整合し、選択が非退化なら、容量制約は両側の裾を過剰にする。

$$\mathbb{P}(|Y - c_0| \geq t \mid D = 1) \geq \mathbb{P}(|Y - c_0| \geq t).$$

この順位整合性は Roy 構造だけからは従わず、実験仮説として検証する。

J字型には非対称性が必要

$$\alpha_+ > \alpha_-$$

または母分布の正側への非対称性があると、5星側が1星側より強く残る。

$$\mathbb{P}(Y = 5 \mid D = 1) - \mathbb{P}(Y = 1 \mid D = 1)$$

は別の対象であり、極端性だけからJ字型とは結論できない。

観測データは完全ケースを含まない **pattern data** である

理論では共通の m 項目を考える。 $K_i \in \{1, \dots, m-1\}$ とし,

$$\mathcal{D}_{m,K_i} = \left\{ d \in \{0, 1\}^m : \sum_{j=1}^m d_j = K_i \right\}.$$

観測データは

$$O_i = (\mathbf{X}_i, \mathbf{V}_i, K_i, \mathbf{D}_i, \mathbf{Y}_{i,\mathbf{D}_i}), \quad \mathbf{Y}_{i,\mathbf{D}_i} = \{Y_{ij} : D_{ij} = 1\}. \quad (\text{O})$$

構造的ゼロ

exact top- $K < m$ では $\mathbb{P}(\mathbf{D}_i = \mathbf{1}_m) = 0$ であり, 完全ケースは観測支持に含まれない。

Supported block が観測可能な同時分布を定める

Supported block

$S \subseteq \{1, \dots, m\}$ に対し

$$R_{iS} = \prod_{j \in S} D_{ij}, \quad \mathbf{Y}_{iS} = (Y_{ij} : j \in S)', \quad \mathcal{C}_{iS} = (\mathbf{X}_i, K_i, \mathbf{V}_{i,-S}).$$

S は

$$\mathbb{P}(R_{iS} = 1 \mid \mathcal{C}_{iS}) > 0$$

を満たすとき **supported** と呼ぶ。exact top- K では $|S| \leq K_i$ が必要である。

ポイント

R_{iS} は「 S の全成分が同時に観測されたか」を表す。したがって各 **block** はスカラーの観測指標を持ち、欠測 IV の条件付きモーメントを定義できる。

識別対象は支持される周辺分布と汎関数である

観測可能な支持

集合 S が supported なら, $R_{iS} = 1$ の観測で $\mathbf{Y}_{iS}$ が同時に現れる。一方, $|S| > K_i$ のブロックは構造的に観測されない。

識別対象

主対象は $\mathbb{E}h(\mathbf{Y}_{ij})$, $\mathbb{P}(\mathbf{Y}_{ij} \in \{1, 5\})$ 。 $K \geq 2$ なら supported pair の共分散も対象になる。 full joint law $P(\mathbf{Y})$ は追加構造なしには対象にしない。

$$\underbrace{|S| \leq K}_{\text{observational support}} \Rightarrow \text{candidate for recovery}, \quad |S| > K \Rightarrow \text{not observed jointly.}$$

定理 1：完全ケース法は構造的ゼロにより適用できない

定理 1（構造的ゼロ下の非識別）

$K < m$ a.s. なら

$$R^{cc} = \mathbf{1}\{\mathbf{D} = \mathbf{1}_m\} = 0 \quad \text{a.s.}$$

したがって complete-case moment

$$\mathbb{E} \left\{ \frac{R^{cc}}{q(\mathbf{Y}, \mathbf{X})} \middle| \mathbf{V}, \mathbf{X} \right\} = 1$$

を満たす q は存在せず，complete-case missing-IV 定理は適用できない。

含意

完全ケースの欠如は有限標本問題ではない。 $R^{cc} = 0$ がデータ生成過程に組み込まれているため，完全ケースを用いる条件付きモーメントは定義できない。

定理 1 : supported block を超える結合分布は非識別である

反例 : $m = 2, K = 1$

$\mathbb{P}(\mathbf{D} = (1, 0)) = \mathbb{P}(\mathbf{D} = (0, 1)) = 1/2$, $\mathbf{D} \perp\!\!\!\perp \mathbf{Y}$ とする。

$$P_A : Y_1, Y_2 \stackrel{i.i.d.}{\sim} \text{Bernoulli}(1/2),$$

$$P_B : Y_1 = Y_2 \sim \text{Bernoulli}(1/2).$$

P_A と P_B は同じ観測データ法則 P_O を生成するが,

$$\text{Cov}_A(Y_1, Y_2) = 0, \quad \text{Cov}_B(Y_1, Y_2) = 1/4.$$

よって full joint law は非識別である。

識別境界

観測データが同じでも未観測の依存構造は異なり得る。追加構造なしに回復できる対象は supported block の法則に限定される。

本文の識別対象は平均・裾確率である

項目 j について

$$R_{ij} = D_{ij}, \quad C_{ij} = (\mathbf{X}_i, K_i, \mathbf{V}_{i,-j}), \quad V_{ij} = Z_{ij}^{pre}$$

とする。 C_{ij} と V_{ij} は全員について観測される。

Target-specific functionals

$$\theta_{j,\tau} = \mathbb{E}\{\tau(Y_{ij}, C_{ij})\},$$

$$\tau_{mean}(y, c) = y, \quad \tau_{tail}(y, c) = \mathbf{1}\{y \in \{1, 5\}\}, \quad \tau_{ext}(y, c) = |y - c_0|.$$

識別方針

full-data law を先に識別するのではなく、実験で比較する平均・裾確率を直接識別する。これにより、分布全体に必要な完備性より弱い条件を利用できる。

仮定 R1–R3

$$\text{R1: } 0 < \mathbb{P}(R_{ij} = 1 \mid Y_{ij}, C_{ij}) \quad \text{a.s.}$$

$$\text{R2: } R_{ij} \perp\!\!\!\perp V_{ij} \mid Y_{ij}, C_{ij}. \quad (\text{SV})$$

$\delta_{j,\tau} \in L^2(V_{ij}, C_{ij})$ が存在して

$$\text{R3: } \mathbb{E}\{\delta_{j,\tau}(V_{ij}, C_{ij}) \mid R_{ij} = 1, Y_{ij}, C_{ij}\} = \tau(Y_{ij}, C_{ij}). \quad (\text{Bridge})$$

作用素による表現

$$(T_j^* \delta)(y, c) = \mathbb{E}\{\delta(V_{ij}, c) \mid R_{ij} = 1, Y_{ij} = y, C_{ij} = c\}.$$

bridge 条件は $\tau \in \text{Range}(T_j^*)$ である。解の存在は必要だが、一意性は要求しない (W. Li et al. 2023)。これは対象識別の便利な十分条件であり、一般的な必要十分条件とは主張しない。R1 が成立しない場合は、対象を itemwise overlap population へ限定する。

定理 2：対象汎関数は full law なしに識別できる

定理 2 (target-specific nonparametric identification)

R1-R3 の下で

$$\theta_{j,\tau} = \mathbb{E} [R_{ij}\tau(Y_{ij}, C_{ij}) + (1 - R_{ij})\delta_{j,\tau}(V_{ij}, C_{ij})]. \quad (\text{TF})$$

右辺は観測データのみの汎関数であるため、 $\theta_{j,\tau}$ はノンパラメトリックに識別される。

なぜ成立するか

R2 により $V_{ij} \mid (Y_{ij}, C_{ij})$ の分布は R_{ij} に依存しない。したがって R3 は非公開者にも同じ条件付き平均を与え、

$$\mathbb{E}\{(1 - R_{ij})\delta_{j,\tau}\} = \mathbb{E}\{(1 - R_{ij})\tau(Y_{ij}, C_{ij})\}.$$

公開部分を加えると (TF) が従う。

5段階評価では bridge 存在条件を rank で確認できる

$Y_{ij} \in \{1, 2, 3, 4, 5\}$ とし, V_{ij} も有限サポートをもつとする。

$$H_j(\mathbf{c}) = [\mathbb{P}(V_{ij} = v \mid R_{ij} = 1, Y_{ij} = y, \mathbf{C}_{ij} = \mathbf{c})]_{y,v}.$$

Target-specific condition

$\boldsymbol{\tau}_j(\mathbf{c}) = (\tau(1, \mathbf{c}), \dots, \tau(5, \mathbf{c}))'$ とすると bridge equation は

$$H_j(\mathbf{c}) \boldsymbol{\delta}_{j,\tau}(\mathbf{c}) = \boldsymbol{\tau}_j(\mathbf{c}).$$

したがって必要なのは

$$\boldsymbol{\tau}_j(\mathbf{c}) \in \text{Range}\{H_j(\mathbf{c})\} \quad \text{a.e. } \mathbf{c}. \quad (\text{RC})$$

完備性との違い

$\text{rank } H_j(\mathbf{c}) = 5$ は全ての τ に対する十分条件だが, 平均や裾確率には (RC) だけでよい。これは full-law 識別の完備性より弱い。

Model 1 : top-K の下では shadow exclusion を追加仮定する

選択写像を

$$R_{ij} = r_j(\mathbf{Y}_i, \mathbf{X}_i, K_i, \boldsymbol{\kappa}_i, \boldsymbol{\epsilon}_i^D)$$

と書く。top-K では R_{ij} が $\mathbf{Y}_{i,-j}$ に依存するため、(SV) は Roy 構造だけから自動的に従わない。

原始的な十分条件の一例

$$V_{ij} \perp\!\!\!\perp (\mathbf{Y}_{i,-j}, \boldsymbol{\epsilon}_i^D, \boldsymbol{\kappa}_i) \mid Y_{ij}, C_{ij}, \quad (\text{P-SV})$$

かつ V_{ij} は Y_{ij}, C_{ij} を固定した後に公開効用 A_{ij} へ直接入らない。このとき未観測の競合評価と選択ショックを周辺化した後も

$$R_{ij} \perp\!\!\!\perp V_{ij} \mid Y_{ij}, C_{ij}$$

が保たれる。

限定

(P-SV) は強い維持仮定であり、実験だけでは証明できない。二波測定・時点付きログ・複数信号・排除制約違反への感度分析で妥当性を補強する。事前期待は期待不一致を通じて公開効用へ直接入り得るため、時間的先行だけでは十分でない。

測定モデル

$$\begin{aligned} F_i &= g(V_i, \mathbf{X}_i) + U_i, & Y_{ij} &= h_j(F_i, \mathbf{X}_i) + \varepsilon_{ij}, \\ \mathbb{E}(U_i \mid V_i, \mathbf{X}_i) &= 0, & \mathbb{E}(\varepsilon_{ij} \mid F_i, \mathbf{X}_i) &= 0. \end{aligned}$$

定理 3 の十分条件

次を仮定する。

1. $K \geq 3$ の層で三つの anchor items a, b, c が jointly supported であり、付録 E の強い完備性条件により $P(Y_a, Y_b, Y_c, V, X)$ が識別される。
2. Y_a, Y_b, Y_c は (F, X) を条件に独立で、対応する条件付き期待値作用素が injective である。
3. F の位置・尺度を正規化する。
4. 各 j について $\{j, a, b\}$ が jointly supported で、同じ injectivity 条件を満たす。

定理 3：測定モデルは supported blocks を接続する

定理 3 (latent measurement extension)

このとき三測定識別の議論 (Y. Hu and Schennach 2008) により, $P(F | V, X)$ と測定 kernel $P(Y_j | F, X)$ が正規化の下で識別される。さらに

$$g(v, x) = \mathbb{E}(F | V = v, X = x), \quad h_j(f, x) = \mathbb{E}(Y_j | F = f, X = x)$$

が識別される。

境界

低ランク構造だけでは vector completeness は従わない。定理 3 には supported anchors, measurement injectivity, 正規化が必要である。これは本文の実験的貢献に必要な仮定ではなく, full-law 回復を目指す発展結果である。

実験 1 : oracle と public を同一標本から取得する

1. 共通候補 30–40 サービスから、少なくとも $J \simeq 10$ の利用経験を持つ参加者を screening する。
2. private rating Y_{ij} , 利用頻度・期間, 課金, 属性を取得して回答を lock する。
3. confirmatory analysis では

$$K_i \in \{1, 3\}, \quad \text{forced random-3}$$

ヘランダム割当する。必要に応じ $K = 5, 10$ を補助群とする。

4. self-selected 群は指定件数だけ公開対象を選び, 選択した対象だけ短い自由記述を書く。基本報酬は評価方向と公開対象に依存させない。
5. 標本数は $n > 100$ の固定値ではなく, 個人内相関と三群比較を含む事前の検出力計算で決定する。

実験 1：shadow 測定時点と検証範囲を分ける

Shadow signal の測定時点

回顧的な利用前期待は recall bias により R2 の valid shadow と自動的にはみなさない。target-specific point identification を主張する confirmatory study では、二波設計またはログにより V_{ij}^{pre} を評価形成前に測る。必要なら倫理審査を変更する。

実験が検証できる範囲

実験は capacity effect, crowd-out, oracle に対する補正性能を評価する。shadow exclusion や bridge の存在そのものをデータだけで証明するものではない。

必要な設計変更

R1-R3 を confirmatory claim にする場合は、倫理審査変更後の二波測定または時点付きプラットフォームログを用いる。現行の回顧測定だけなら、付録の単調性 bounds と感度分析を併記する。

Oracle と naive を同じ person-average target で比較する

person-average target を

$$\theta_h = \mathbb{E} \left\{ \frac{1}{m} \sum_{j=1}^m h(Y_{ij}) \right\}$$

と固定する。完全データによる oracle は

$$\hat{\theta}_h^{\text{oracle}} = \frac{1}{n} \sum_{i=1}^n \frac{1}{m} \sum_{j=1}^m h(Y_{ij}).$$

exact K_i の公開レビューだけを等しく個人加重する naive 推定量は

$$\hat{\theta}_h^{\text{naive}} = \frac{1}{n} \sum_{i=1}^n \frac{1}{K_i} \sum_{j=1}^m D_{ij} h(Y_{ij}).$$

比較の単位

oracle と naive をともに個人平均として定義し、項目数や公開数の違いによって参加者の重みが変わらないようにする。naive は選択下で一般に θ_h へ一致しない。

Representer bridge の有限標本回復を oracle で評価する

定理 2 に基づく target-specific 推定量は

$$\hat{\theta}_{\tau}^{rep} = \frac{1}{nm} \sum_{i=1}^n \sum_{j=1}^m \left[D_{ij} \tau(Y_{ij}, C_{ij}) + (1 - D_{ij}) \hat{\delta}_{j,\tau}(V_{ij}, C_{ij}) \right].$$

事前登録する主要対象

$$\tau_1(y, c) = |y - c_0|, \quad \tau_2(y, c) = \mathbf{1}\{y \in \{1, 5\}\}, \quad \tau_3(y, c) = y,$$

および own-rating を固定した competitor extremity の crowd-out 効果。

$$H_{rec} : |\hat{\theta}_{\tau}^{rep} - \hat{\theta}_{\tau}^{oracle}| < |\hat{\theta}_{\tau}^{naive} - \hat{\theta}_{\tau}^{oracle}|$$

を有限標本上の回復仮説として評価する。成立しても識別仮定の真実性そのものは証明しない。

Pooling の条件

項目間で共通 bridge を仮定しない場合、 $\hat{\delta}_{j,\tau}$ は項目別に推定してから平均する。pooling するには項目交換可能性または共通 bridge を追加仮定する。

実験 2 はランキングをランダム化して増幅を識別する

実験 1 の公開レビュー pool $\mathcal{P}$ から、同じ表示数 L の feed を作る。閲覧者を

$$G_i \in \{\text{random order, helpfulness rank, LLM rank}\}$$

へランダム割当し、score と tie-breaking rule を事前固定する。

主要比較

$$\Delta_{\text{alg}}(h) = \mathbb{E}\{h(Y) \mid \text{rank} \leq L, G = \text{alg}\} - \mathbb{E}\{h(Y) \mid \text{rank} \leq L, G = \text{random}\}.$$

$$F_Y^{\text{oracle}} \longrightarrow F_{Y|D^{\text{post}}=1}^{\text{public}} \longrightarrow F_{Y|D^{\text{post}}=1, \text{rank} \leq L, G}^{\text{feed}}.$$

補助命題と実験を分ける

score s が極端性 $e = |Y - c_0|$ に単調増加なら、決定論的 top- L について

$$\mathbb{E}(e \mid \text{rank}_s \leq L) \geq \mathbb{E}(e \mid D^{\text{post}} = 1).$$

実験ではこの単調性を仮定せず、random feed との差として実際の増幅を推定する。helpfulness 評価には proper scoring / peer-prediction を事前指定する。

結論：多変量 MNAR の対象汎関数を回復し、レビューで検証する

1. 新しい多変量 **MNAR** 表現 exact top- K を構造的ゼロと cross-item crowd-out をもつ多変量 MNAR として実装する。
2. 非識別の境界 exact top- K では完全ケースが構造的に存在せず, full joint law は一般に非識別である。
3. 正の識別結果 shadow exclusion と target-specific representer の存在により, 平均・裾確率を full law なしにノンパラメトリックに識別する。
4. 実験 ランダム化した K とランキングにより, 選択機構, oracle 回復性能, アルゴリズム増幅を分けて評価する。
5. 位置づけ 選択方程式は generalized Roy model に含まれ, shadow-variable 法の Roy 応用自体は既知である。新規性は dependent MNAR の定式化, 識別境界, ランダム化検証に置く。

中心メッセージ

Reviews compete for scarce disclosure slots;
target functionals can be recovered without identifying the full law.

- Berger, J. (2014). “Word of Mouth and Interpersonal Communication: A Review and Directions for Future Research”. In: *Journal of Consumer Psychology* 24.4, pp. 586–607. DOI: 10.1016/j.jcps.2014.05.002.
- d’Haultfoeuille, X. (2010). “A New Instrumental Method for Dealing with Endogenous Selection”. In: *Journal of Econometrics* 154.1, pp. 1–15. DOI: 10.1016/j.jeconom.2009.06.005.
- Di Tillio, A., M. Ottaviani, and P. N. Sørensen (2021). “Strategic Sample Selection”. In: *Econometrica* 89.2, pp. 911–953. DOI: 10.3982/ECTA17288.
- Hennig-Thurau, T., K. P. Gwinner, G. Walsh, and D. D. Gremler (2004). “Electronic Word-of-Mouth via Consumer-Opinion Platforms: What Motivates Consumers to Articulate Themselves on the Internet?” In: *Journal of Interactive Marketing* 18.1, pp. 38–52. DOI: 10.1002/dir.10073.
- Hu, N., P. A. Pavlou, and J. Zhang (2017). “On Self-Selection Biases in Online Product Reviews”. In: *MIS Quarterly* 41.2, pp. 449–471. DOI: 10.25300/MISQ/2017/41.2.06.

- Hu, Y. and S. M. Schennach (2008). “Instrumental Variable Treatment of Nonclassical Measurement Error Models”. In: *Econometrica* 76.1, pp. 195–216. DOI: 10.1111/j.0012-9682.2008.00823.x.
- Li, W., W. Miao, and E. J. Tchetgen Tchetgen (2023). “Non-parametric Inference about Mean Functionals of Non-ignorable Non-response Data without Identifying the Joint Distribution”. In: *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 85.3, pp. 913–935. DOI: 10.1093/jrssl/qkad047.
- Li, Y., W. Miao, I. Shpitser, and E. J. Tchetgen Tchetgen (2023). “A Self-Censoring Model for Multivariate Nonignorable Nonmonotone Missing Data”. In: *Biometrics* 79.4, pp. 3203–3214. DOI: 10.1111/biom.13916.
- Malinsky, D., I. Shpitser, and E. J. Tchetgen Tchetgen (2022). “Semiparametric Inference for Nonmonotone Missing-Not-at-Random Data: The No Self-Censoring Model”. In: *Journal of the American Statistical Association* 117.539, pp. 1415–1423. DOI: 10.1080/01621459.2020.1862669.
- Miao, W. and E. J. Tchetgen Tchetgen (2016). “On Varieties of Doubly Robust Estimators under Missingness Not at Random with a Shadow Variable”. In: *Biometrika* 103.2, pp. 475–482. DOI: 10.1093/biomet/asw016.

- Schoenmueller, V., O. Netzer, and F. Stahl (2020). “The Polarity of Online Reviews: Prevalence, Drivers and Implications”. In: *Journal of Marketing Research* 57.5, pp. 853–877. DOI: 10.1177/0022243720941832.
- Zhao, J. and J. Shao (2015). “Semiparametric Pseudo-Likelihoods in Generalized Linear Models with Nonignorable Missing Data”. In: *Journal of the American Statistical Association* 110.512, pp. 1577–1590. DOI: 10.1080/01621459.2014.983234.

付録 A：スカラー欠測 IV のノンパラメトリック識別

d'Haultfoeuille 型の基本仮定

$$R = 1 \Rightarrow Y \text{ observed}, \quad R \perp\!\!\!\perp V \mid Y, X,$$

$$\pi(Y, X) = \mathbb{P}(R = 1 \mid Y, X) > 0.$$


任意の下有界・可積分 g について

$$\mathbb{E}\{g(Y, X) \mid V, X\} = 0 \Rightarrow g(Y, X) = 0.$$

識別モーメント

$$\mathbb{E} \left\{ \frac{R}{\pi(Y, X)} \mid V, X \right\} = 1.$$

完備性により π は唯一解である。



d'Haultfoeuille (2010) and Miao and Tchetgen Tchetgen (2016).

付録 B : Zhao-Shao の conditional shadow 表現

常時観測共変量を X とし

$$\mathbb{P}(R = 1 \mid Y, V, X) = \mathbb{P}(R = 1 \mid Y, X) \iff R \perp\!\!\!\perp V \mid Y, X.$$

回答者データ上で

$$\begin{aligned} f(v \mid y, x, R = 1) &= \frac{\mathbb{P}(R = 1 \mid v, y, x) f(v \mid y, x)}{\mathbb{P}(R = 1 \mid y, x)} \\ &= f(v \mid y, x). \end{aligned}$$

Bayes 則から

$$f(v \mid y, x) = \frac{f(y \mid v, x) f(v \mid x)}{\int f(y \mid t, x) f(t \mid x) dt}.$$

本研究との関係

Zhao-Shao は GLM パラメータの semiparametric 識別・推定を扱う。本研究の定理 2 は, target-specific representer の存在により平均・裾確率を full-data law なしにノンパラメトリックに識別する。

Source: Zhao and Shao (2015).

$$R^{cc} = \mathbf{1}\{\mathbf{D} = \mathbf{1}_m\}, \quad \pi^{cc}(\mathbf{Y}, \mathbf{X}) = \mathbb{P}(R^{cc} = 1 \mid \mathbf{Y}, \mathbf{X}).$$

Complete-case vector missing-IV theorem

$R^{cc} \perp\!\!\!\perp \mathbf{V} \mid \mathbf{Y}, \mathbf{X}$, $\pi^{cc} > 0$, および

$$\mathbb{E}\{g(\mathbf{Y}, \mathbf{X}) \mid \mathbf{V}, \mathbf{X}\} = 0 \Rightarrow g(\mathbf{Y}, \mathbf{X}) = 0$$

が成り立つとする。正值関数 q が

$$\mathbb{E}\left\{\frac{R^{cc}}{q(\mathbf{Y}, \mathbf{X})} \mid \mathbf{V}, \mathbf{X}\right\} = 1$$

を満たす正值関数 q を考える。

一意性

前頁の仮定の下で

$$q(\mathbf{Y}, \mathbf{X}) = \pi^{\text{cc}}(\mathbf{Y}, \mathbf{X}) \quad \text{a.s.}$$

であり、完全ケース選択確率と full-data law が識別される。

適用範囲

この結果は $\mathbb{P}(R^{\text{cc}} = 1) > 0$ の場合の benchmark である。exact top- $K < m$ では $R^{\text{cc}} = 0$ a.s. なので本文の定理 2 へ置き換える必要がある。

付録 D：完全ケース版の一意性証明

真の π^{cc} と候補解 q に対し

$$g(\mathbf{Y}, \mathbf{X}) = \frac{\pi^{\text{cc}}(\mathbf{Y}, \mathbf{X})}{q(\mathbf{Y}, \mathbf{X})} - 1$$

と置く。すると

$$\begin{aligned} 0 &= \mathbb{E} \left[R^{\text{cc}} \left\{ \frac{1}{q} - \frac{1}{\pi^{\text{cc}}} \right\} \middle| \mathbf{V}, \mathbf{X} \right] \\ &= \mathbb{E} \left[\pi^{\text{cc}} \left\{ \frac{1}{q} - \frac{1}{\pi^{\text{cc}}} \right\} \middle| \mathbf{V}, \mathbf{X} \right] \\ &= \mathbb{E}\{g(\mathbf{Y}, \mathbf{X}) \mid \mathbf{V}, \mathbf{X}\}. \end{aligned}$$

$g \geq -1$ で、モーメント条件から $\mathbb{E}(\pi^{\text{cc}}/q) = 1$ ，したがって

$$\mathbb{E}|g| \leq 2.$$

$\mathcal{B}$ -completeness により $g = 0$ a.s., すなわち $q = \pi^{\text{cc}}$ 。

付録 E：分布全体の識別には強い仮定を置く

supported block S について

$$\pi_S(\mathbf{Y}_S, \mathcal{C}_S) = \mathbb{P}(R_S = 1 \mid \mathbf{Y}_S, \mathcal{C}_S)$$

とする。

仮定 B1–B3

$$\text{B1: } \pi_S(\mathbf{Y}_S, \mathcal{C}_S) > 0 \quad \text{a.s.,}$$

$$\text{B2: } R_S \perp\!\!\!\perp \mathbf{V}_S \mid \mathbf{Y}_S, \mathcal{C}_S,$$

任意の下有界・可積分な a について

$$\text{B3: } \mathbb{E}\{a(\mathbf{Y}_S, \mathcal{C}_S) \mid \mathbf{V}_S, \mathcal{C}_S\} = 0 \Rightarrow a(\mathbf{Y}_S, \mathcal{C}_S) = 0.$$

本文との違い

本文の **representer bridge** は一つの τ に対する解の存在だけを要求する。B3 は全ての関数を分離する完備性であり、**full-law** 識別のための強い条件である。

Inverse-selection bridge

$$\omega_S(\mathbf{Y}_S, \mathcal{C}_S) = \frac{1}{\pi_S(\mathbf{Y}_S, \mathcal{C}_S)}, \quad \mathbb{E}\{R_S \omega_S(\mathbf{Y}_S, \mathcal{C}_S) \mid \mathbf{V}_S, \mathcal{C}_S\} = 1. \quad (\text{ISB})$$

B1-B3 の下で ω_S は (ISB) の唯一の正值解である。したがって

$$\mathbb{E}h(\mathbf{Y}_S, \mathbf{V}_S, \mathcal{C}_S) = \mathbb{E}\{R_S \omega_S(\mathbf{Y}_S, \mathcal{C}_S) h(\mathbf{Y}_S, \mathbf{V}_S, \mathcal{C}_S)\} \quad (\text{BR})$$

により supported-block law がノンパラメトリックに識別される。

二つの bridge を区別する

representer bridge : target-specific, 存在のみ, 一意性不要。

inverse-selection bridge : full law, 一意性と完備性が必要。

付録 E : supported-block 定理の証明

真の π_S は B2 から

$$\mathbb{E} \left\{ \frac{R_S}{\pi_S(\mathbf{Y}_S, \mathcal{C}_S)} \middle| \mathbf{Y}_S, \mathbf{V}_S, \mathcal{C}_S \right\} = 1$$

を満たす。候補解 q_S に対し

$$g_S(\mathbf{Y}_S, \mathcal{C}_S) = \frac{\pi_S(\mathbf{Y}_S, \mathcal{C}_S)}{q_S(\mathbf{Y}_S, \mathcal{C}_S)} - 1$$

と置くと

$$\mathbb{E}\{g_S(\mathbf{Y}_S, \mathcal{C}_S) \mid \mathbf{V}_S, \mathcal{C}_S\} = 0.$$

$g_S \geq -1$, $\mathbb{E}|g_S| \leq 2$ なので B3 により $g_S = 0$ a.s., よって $q_S = \pi_S$ 。さらに反復期待値から

$$\begin{aligned} \mathbb{E} \left[\frac{R_S}{\pi_S(\mathbf{Y}_S, \mathcal{C}_S)} h(\mathbf{Y}_S, \mathbf{V}_S, \mathcal{C}_S) \middle| \mathbf{Y}_S, \mathbf{V}_S, \mathcal{C}_S \right] \\ = h(\mathbf{Y}_S, \mathbf{V}_S, \mathcal{C}_S), \end{aligned}$$

したがって回復式 (BR) が従う。

付録 F：有限サポートの完備性は rank 条件になる

$\mathbf{Y}_S$ の条件付きサポートを $\{y_1, \dots, y_s\}$, $\mathbf{V}_S$ のサポートを $\{v_1, \dots, v_t\}$ とする。

$$M_S(\mathbf{c}) = [\mathbb{P}(\mathbf{Y}_S = y_a \mid \mathbf{V}_S = v_b, \mathcal{C}_S = \mathbf{c})]_{b=1, \dots, t; a=1, \dots, s}.$$

有限サポート条件

$$\text{rank } M_S(\mathbf{c}) = s \quad \text{a.e. } \mathbf{c}$$

なら

$$\mathbb{E}\{a(\mathbf{Y}_S, \mathbf{c}) \mid \mathbf{V}_S, \mathbf{c}\} = 0 \Rightarrow a(\mathbf{Y}_S, \mathbf{c}) = 0.$$

Weak-but-many の意味

単一信号では $\text{rank } M_S < s$ でも、異質な複数信号を組み合わせせた $\mathbf{V}_S^{(L)}$ により行数と分離能力が増え、full column rank を満たし得る。ただし相互に同じ情報の複製なら rank は増えない。

Self-censoring

$$D_j \perp\!\!\!\perp \mathbf{Y}_{-j} \mid (\mathbf{X}, Y_j, \mathbf{D}_{-j}).$$

さらに supported pattern set $\mathcal{R}$ について

$$p(d \mid x, y) > c > 0 \quad (d \in \mathcal{R}),$$

$$d \in \mathcal{R}, d \leq d' \implies d' \in \mathcal{R}.$$

最後の upward closure により, supported pattern から観測項目を追加した pattern も必要になる。

Source: Y. Li et al. (2023).

Exact top- K

$$\mathcal{D}_{m,K} = \{d : \sum_j d_j = K\}.$$

$d \in \mathcal{D}_{m,K}$ に対し $d' > d$ なら $\sum_j d'_j > K$ なので $d' \notin \mathcal{D}_{m,K}$ 。したがって upward closure は成立しない。

相違は **conditional independence** だけではない

top- K と既存モデルの相違は, censor relation に加え, positivity, complete-case support, pattern support の幾何にある。

各人の tail 件数を

$$M_i = \sum_{j=1}^m \mathbf{1}(Y_{ij} \in \{1, 5\})$$

とする。公開集合が評価と独立な一様選択なら

$$\mathbf{D}_i \mid \mathbf{Y}_i, K_i \sim \text{Unif}(\mathcal{D}_{m, K_i}).$$

公開 tail 件数

$$S_i = \sum_{j=1}^m D_{ij} \mathbf{1}(Y_{ij} \in \{1, 5\})$$

は

$$S_i \mid M_i, K_i \sim \text{Hypergeometric}(m, M_i, K_i).$$

$$\mathbb{E}_0(S_i \mid M_i, K_i) = K_i \frac{M_i}{m},$$

$$\text{Var}_0(S_i \mid M_i, K_i) = K_i \frac{M_i}{m} \left(1 - \frac{M_i}{m}\right) \frac{m - K_i}{m - 1}.$$

$m = 10, K = 3$ なら $\binom{10}{3} = 120$ 通りを個人ごとに列挙できる。

付録 I : Model 2 は単調性による部分識別である

過去利用変数 V_{ij} が現在評価を固定しても公開に直接影響することを許し, 順序 $v' \succeq v$ に対して

$$\pi_j(y, v', c) \geq \pi_j(y, v, c) \quad (\text{M2-MON})$$

のみを置く。観測データ法則を P_O とする。

ノンパラメトリック候補集合

$$\mathcal{P}_{M2}(P_O) = \{P : P \mapsto P_O, \pi_j > 0, (\text{M2-MON}) \text{ holds}\},$$

$$\Theta_h^{M2}(P_O) = \{\mathbb{E}_P h(Y_j) : P \in \mathcal{P}_{M2}(P_O)\}.$$

識別主張

単調性だけでは $\Theta_h^{M2}(P_O)$ は一般に一点にならない。Model 2 の対象は点推定ではなく, 部分識別集合と感度分析である。

付録 I：有限サポートの bounds を計算する

有限サポートの identified set

Y_j, V_{ij}, C_{ij} が有限サポートなら

$$\underline{\theta}_h = \inf_{P \in \mathcal{P}_{M_2}(P_0)} \mathbb{E}_P h(Y_j), \quad \bar{\theta}_h = \sup_{P \in \mathcal{P}_{M_2}(P_0)} \mathbb{E}_P h(Y_j).$$

閉性・コンパクト性と端点の実現可能性を別途示した場合に限り，min/max で達成される sharp bounds と呼ぶ。

本文に置かない理由

本文の主結果は target-specific point identification である。Model 2 は exclusion 違反に対する頑健性・感度分析として位置づける。

付録 J : Model 3 は weak-but-many signals を用いる

項目 j に対して常時観測される事前信号を

$$\mathbf{V}_{ij}^{(L)} = (V_{ij1}, \dots, V_{ijL})'$$

とする。各信号が弱くても、ベクトルとして

$$D_{ij} \perp\!\!\!\perp \mathbf{V}_{ij}^{(L)} \mid Y_{ij}, C_{ij} \quad (\text{M3-SV})$$

を満たし、対象 τ について

$$\tau(\cdot, \mathbf{c}) \in \text{Range}(T_{j,L}^*) \quad (\text{M3-R})$$

なら本文の representer bridge を適用できる。

必要なのは共同の分離能力

単一信号の第一段階が弱くても、異質な信号が Y_j の対象方向を共同で分離すればよい。予測精度や信号数だけでは bridge 存在は保証されない。

付録 J：有限サポートでは rank と range を区別する

Target-specific condition

Y_j のサポート数を s とし

$$H_L(\mathbf{c}) = \left[\mathbb{P}(\mathbf{V}_j^{(L)} = \mathbf{v}_b \mid D_j = 1, Y_j = y_a, C_j = \mathbf{c}) \right]_{a,b}.$$

$$\boldsymbol{\tau}(\mathbf{c}) \in \text{Range}\{H_L(\mathbf{c})\} \implies \text{target-specific bridge exists.}$$

全ての $\boldsymbol{\tau}$ を扱う十分条件は $\text{rank } H_L(\mathbf{c}) = s$ である。

集約時の注意

$F_{ij}^{pre} = T_L(\mathbf{V}_{ij}^{(L)})$ に集約する場合も、 $\boldsymbol{\tau}(\mathbf{c}) \in \text{Range}\{H_F(\mathbf{c})\}$ を別途確認する必要がある。
weak-but-many は自動的に completeness や bridge 存在を保証しない。